Pre-registration

B5. Derandomized augmentation как изолированная гипотеза

Георгий Тхостов, Владимир Шама | БКНАД241 | 08.11.2026

1. Статья и главная гипотеза

В статье Keller Jordan «94% on CIFAR-10 in 3.29 Seconds on a Single GPU» (2024) автор утверждает, что чередование горизонтальных отражений изображений между эпохами обучения повышает точность классификации по сравнению с обычными случайными отражениями, если использование отражений в целом улучшает качество модели.

2. Ядро воспроизведения

Для воспроизведения выбрана таблица 6 из приложения D оригинальной статьи. Будем сравнивать три способа горизонтального отражения изображений: без отражений (None), случайные отражения (Random) и чередующиеся отражения (Alternating). Эксперименты проведём на датасете CIFAR-10 с использованием модели airbench94. Рассмотрим обучение в течение 10 и 20 эпох без Cutout и TTA.

Основная метрика - точность классификации (accuracy) на тестовой выборке. В статье для 10 эпох получены значения 92,3053%, 93,0988% и 93,2798%, а для 20 эпох - 92,8166%, 93,7446% и 93,8652% соответственно.

Для каждой конфигурации планируем провести 50 запусков с разными случайными сидами. Будем сравнивать среднюю точность с результатами статьи, а также рассчитывать стандартное отклонение и 95%-й доверительный интервал.

Численные результаты будем считать воспроизведёнными, если отклонение средней точности от опубликованных значений не превысит 0,15 процентного пункта. Такой порог выбран с учётом разброса исходных запусков, где стандартное отклонение составляло около 0,139 процентного пункта.

Основную гипотезу будем считать подтверждённой в выбранных условиях, если alternating flip покажет более высокую среднюю точность, чем random flip, при 10 и 20 эпохах, а 95%-е доверительные интервалы разности точностей не будут включать ноль.

3. Запуск оригинального кода

Для проверки работоспособности оригинальной реализации был использован скрипт airbench94.py из репозитория автора. Код удалось запустить без изменений. Потребовалось только обновить библиотеки для совместимости с видеокартой и скачать датасет CIFAR-10 с другого источника.

Эксперимент проводился на NVIDIA GeForce RTX 5070 (12 ГБ) под Windows 11. Использовались Python 3.12.9, PyTorch 2.14.1+cu130, Torchvision 0.29.1+cu130 и CUDA 13.0.

Было выполнено 25 обучений по 9,9 эпох. Средняя точность без TTA составила 93,262% со стандартным отклонением 0,139 процентного пункта, а с TTA - 94,021% со стандартным отклонением 0,153 процентного пункта. В оригинальной статье точность с TTA составляет 94,01%, поэтому полученный результат отличается всего на 0,011 процентного пункта.

Среднее время одного обучения составило 25,95 секунды, общее время выполнения - 672,5 секунды. Полные логи, результаты запусков и информация об окружении сохранены в GitHub-репозитории проекта в папке results/checkpoint1/original.

4. Проверяемые недочёты

Первое ограничение статьи связано с утверждением, что alternating flip лучше случайных отражений во всех случаях, когда горизонтальные отражения полезны. Авторы проверили это на нескольких конфигурациях, но такой результат не обязательно сохраняется при любых условиях обучения. Мы проверим его для 10 и 20 эпох, сравнив точность без отражений, со случайными и чередующимися отражениями. Для оценки различий будем использовать средние значения accuracy и 95%-е доверительные интервалы разности точностей.

Второй вопрос связан с влиянием других аугментаций. В оригинальной модели помимо отражений используются случайные сдвиги изображений. Мы проверим, как изменение параметра translate влияет на преимущество alternating flip. Для этого проведём эксперименты со значениями translate = 0, 2 и 4 при 10 эпохах обучения. В каждом случае сравним три режима отражений на 50 сидах, сохранив остальные параметры модели неизменными.

5. Улучшение / расширение

В качестве дополнительного эксперимента планируем проверить, как интенсивность случайных сдвигов изображений влияет на эффективность alternating flip. Для этого изменим параметр translate, который в оригинальной модели равен 2, и рассмотрим значения 0, 2 и 4. При каждом значении сравним обучение без отражений, со случайными и чередующимися отражениями. Эксперименты проведём на CIFAR-10 в течение 10 эпох, по 50 запусков на каждую конфигурацию. Остальные настройки модели оставим неизменными. Основной интерес представляет изменение разницы в средней точности между alternating flip и random flip при разных значениях translate. Это позволит оценить, насколько преимущество чередующихся отражений зависит от интенсивности других аугментаций.

6. Ожидаемые результаты

При воспроизведении таблицы 6 ожидаем, что средняя точность по всем шести конфигурациям будет отличаться от результатов статьи не более чем на 0,15 процентного пункта. Предполагаем, что alternating flip сохранит преимущество перед random flip примерно на 0,18 процентного пункта при 10 эпохах и на 0,12 при 20 эпохах.

При проверке ограничений статьи ожидаем, что случайные отражения будут улучшать точность по сравнению с отсутствием отражений примерно на 0,79 и 0,93 процентного пункта при 10 и 20 эпохах соответственно. Также предполагаем, что преимущество alternating flip окажется статистически значимым в обоих случаях, а 95%-е доверительные интервалы разности точностей не будут включать ноль.

В дополнительном эксперименте ожидаем, что увеличение параметра translate будет уменьшать преимущество alternating flip перед random flip. При translate = 0 предполагаем разницу около 0,25 процентного пункта, при translate = 2 - около 0,18, при translate = 4 - около 0,10. Эти значения являются предварительными предположениями, которые будем проверять в ходе экспериментов.

7. Бюджет и план работы

Для оценки вычислительных затрат было проведено 12 пилотных запусков на NVIDIA GeForce RTX 5070. Среднее время обучения составляет примерно 26,8 секунды для 10 эпох и 52,9 секунды для 20 эпох.

Основное исследование включает 6 конфигураций по 50 запусков, всего 300 обучений. По результатам пилота на это потребуется около 3 часов 19 минут. Дополнительный эксперимент с параметром translate включает 450 запусков, но 150 из них совпадают с основным исследованием и могут быть использованы повторно. Поэтому дополнительно потребуется около 2 часов 14 минут. Общий вычислительный бюджет составляет примерно 5,5 часа без учёта возможных повторных запусков и обработки результатов.

Работа в команде распределена следующим образом: Георгий Тхостов отвечает за изучение статьи, формулировку гипотез, планирование экспериментов, анализ результатов и подготовку документации. Владимир Шама отвечает за программную реализацию, настройку окружения, запуск экспериментов и сбор метрик. Интерпретация итоговых результатов и подготовка к защите выполняются совместно.

Если вычислительных ресурсов или времени окажется недостаточно, в первую очередь сократим дополнительный эксперимент, оставив значения translate = 0 и 2. При необходимости уменьшим количество сидов с 50 до 20, сохранив приоритет основного воспроизведения. Все изменения первоначального плана будем фиксировать в журнале решений DECISIONS.md.

8. Использование LLM

При подготовке проекта использовались Claude и ChatGPT.

Claude применялся для помощи в написании и проверке программного кода, настройке рабочего окружения и анализе полученных результатов.

ChatGPT использовался для подробного разбора научной статьи, объяснения отдельных терминов, проверки корректности описания гипотез и экспериментов, исправления грамматических ошибок и оформления текста документа.

Все численные результаты получены в ходе реальных запусков программы. Итоговые формулировки и исследовательские решения проверялись и согласовывались участниками команды.

Источники и материалы

Keller Jordan (2024). 94% on CIFAR-10 in 3.29 Seconds on a Single GPU. arXiv:2404.00498. https://arxiv.org/abs/2404.00498

Репозиторий проекта: https://github.com/BubbyGit/dl-project-b5

Исходный код: https://github.com/KellerJordan/cifar10-airbench